

Что нужно от тебя, чтобы это реально запустить

Деньги, аккаунты, выбор лицензий и содержательные решения про персонажа — то, что нельзя решить без тебя.

1. GPU-провайдер и деньги

- Аккаунт на RunPod (или Vast.ai) с привязанной картой/балансом.
- Решение: даёшь API-ключ RunPod, чтобы под поднимался и останавливался автоматически из скрипта, или поднимаешь под сам по инструкции в `deploy/runpod_setup.md`, а работа идёт по SSH внутри уже поднятого пода.
- Ориентировочный бюджет на прогон (RTX 4090, community cloud, ~\$0.35–0.45/час): холодный старт + установка окружения 15–25 мин, генерация 8 фото + видео 5–10 мин активного GPU-времени. Полная сессия «от нуля до готовых 8 фото + видео» — в районе \$0.3–0.6, не считая времени на ручной ревью между шагами.

2. Чекпойнт (базовая модель)

В `C:\projects\WET` (WetDreams — тот же продукт, боевой Telegram-бот + сайт) уже есть проверенный на проде RunPod-воркер с тремя реальными чекпойнтами на Civitai:

Ключ	Файл	Civitai model_id	Планировщик
<code>wai-nsfw-illustrious-sdxl</code> (дефолт у них)	<code>wai-nsfw-illustrious-sdxl.safetensors</code>	2167369	Euler Ancestral
<code>real</code>	<code>realismIllustriousBy_v50FP16.safetensors</code>	2091367	Euler Ancestral
<code>cyberrealisticPony_v140</code>	<code>cyberrealisticPony_v140.safetensors</code>	2255476	DPM Solver SDE + Karras

Это Illustrious-XL / Pony-XL — самостоятельные SDXL-архитектурные файнтюны, не ванильный SDXL 1.0.

Технический риск для проверки на живом поде, не заранее: IP-Adapter-FaceID для SDXL обучен на базовом SDXL 1.0 UNet. Архитектурно он совместим и с Illustrious/Pony, но точность identity-lock на них эмпирически не гарантирована на том же уровне, что на ванильном SDXL — это первое, что стоит замерить в тестовом прогоне, до генерации всех 8 фото.

(а) взять готовый `real` или `wai-nsfw-illustrious-sdxl` — плюс: уже лицензионно разобран и проверен в проде на RunPod; минус: непроверенная FaceID-совместимость.

(б) взять ванильный SDXL 1.0 base (CreativeML Open RAIL++-M, коммерческое использование разрешено) — плюс: FaceID для него validated по документации h94/IP-Adapter-FaceID; минус: фотореализм ниже специализированных чекпойнтов.

Скажи, какой вариант, или дай третий чекпойнт на свой вкус — подставлю его в `pipeline/generate_photos.py` (сейчас там ванильный SDXL 1.0 как безопасный дефолт).

3. Границы контента

Судя по промпт-шаблонам `image_prompt_templates/realistic.txt` и `anime.txt` в `WET/tg-bot`, в проде уже принята формулировка: **«fictional consenting adults (21+)»**, explicit/NSFW разрешён, жёсткий запрет на несовершеннолетних и hard gore.

Если этот проект — расширение WetDreams (устойчивое лицо персонажа вместо каждый раз новой генерации), беру эту формулировку как рабочую вместо SFW-по-умолчанию из первой версии. Это меняет:

- safety-гейт (`safety/moderation_pipeline.py`) — NSFW сам по себе перестаёт быть поводом блокировать, блокирует только несовершеннолетие и совпадение с реальным лицом (одна строка в конфиге гейта, применю после подтверждения);
- возрастной порог в character bible и в коде (`min_allowed_age`) — поднимаю до консистентности с «21+» вместо произвольных «25 с запасом от 18+».

Если это **не** для WetDreams, а отдельный SFW-продукт — скажи прямо, оставляю как было (NSFW блокирует).

4. Character bible — «легенда» персонажа

Шаблон в `character/character_bible_template.md`. Нужно заполнить или утвердить:

- имя персонажа (для внутренних файлов/промптов);
- возрастной диапазон «выглядит на» — нужно число, не «взрослая»: входит в порог age-gate;
- этнические/внешние черты, цвет глаз/волос, телосложение, отличительные черты;
- общий стиль 8 сцен (город/офис/природа/студия — конкретный список, не абстрактный).

5. Watchlist для проверки «не похожа на реального человека»

Если есть конкретный список людей, на которых персонаж точно не должен быть похож (публичные фигуры, конкретные частные лица) — дай список имён или фото, соберу из них галерею эмбеддингов для сверки. Без списка safety-слой всё равно работает (age-gate, NSFW-gate, синтетическое происхождение лица), но проверка на конкретных «запрещённых» лицах активна только при наличии сравнения.

6. HuggingFace-токен

Beca IP-Adapter-FaceID и модель InsightFace `antelopev2` лежат за gated-доступом на HuggingFace — нужен HF-аккаунт с принятыми лицензиями этих репозиторийов и токен для скачивания на под.

7. Кто оперирует подом

- (а) готовлю одну команду/скрипт, запускаешь на поде сам и присылаешь логи/файлы — или
- (б) даёшь SSH/API доступ к поду, пайплайн гоняется напрямую, отчёт готовыми файлами и таблицей.

8. Что уже взято из WetDreams и что осталось решить

- Три чекпойнта и негативный промпт для реалистичного стиля — взяты как готовые кандидаты (п.2); негативный промпт из `realistic.txt` -профиля уже подставлен в `pipeline/generate_photos.py` как дефолт.
- Структура промпт-инжиниринга (LLM конвертирует character bible в теговый SDXL-промпт) — взята как паттерн, адаптирована под статичные 8 сцен вместо чата, лежит в новом `pipeline/prompt_engineering.py`. Нужен ключ OpenRouter (`OPENROUTER_API_KEY`) — тот же провайдер, что уже используется в WetDreams, либо свой LLM API.
- RunPod-архитектура WetDreams (RabbitMQ + FastAPI result-consumer + S3 + вебхук) — не повторяю здесь: для разового прогона 8 фото + 1 видео это лишняя инфраструктура. Если цель — не разовая демонстрация, а постоянная фишка внутри самого WetDreams, объём работы меняется качественно: новый чекпойнт-профиль в `MODEL_CONFIGS`, реализация `_apply_lora_weights` /IP-Adapter в `generation.py` (сейчас заглушка), video-worker как отдельный тип задачи в тех же очередях. Отдельный, кратно больший проект — скажи, если нужен именно он.
- LoRA-хуки в проде WetDreams заведены в схеме (`lora_weights` в `GenerationRequest`), но не реализованы. IP-Adapter FaceID — не временный обходной путь, а пока единственный рабочий вариант identity-lock вообще.

Пока это не решено — весь код и workflow-логика написаны и готовы (`pipeline/`, `safety/`, `deploy/cost_calculator.py`, `scripts/seed_manager.py`), но не запускались на реальном GPU: цифры времени и стоимости в `benchmarking/benchmark_log.csv` появятся после первого прогона на арендованном поде.